Guía de estudio: modelo predictivo para el sistema de control y recolección de aceite

Proyecto Integrador I · Universidad Central del Este · Guía preparada con Claude

Esta guía está ordenada de lo básico a lo avanzado, y cada bloque corresponde a una de las 4 opciones del plan. Casi todo es gratis y en inglés. En YouTube puedes activar los subtítulos traducidos al español.

El plan

1. **Regresión mejorada como modelo principal:** efecto por negocio, interacción tipo × día, GLM para evitar negativos y una variable del mismo día de la semana anterior.
2. **Referencia simple adicional:** la tasa de llenado reciente de la celda de carga, útil para estimar cuándo se llega al 80%.
3. **Datos simulados solo para probar el software:** validar el flujo completo (datos → modelo → alerta → ruta) y hacer análisis de sensibilidad. Cada registro se marca como `sintético` o `real`.
4. **Random Forest o Gradient Boosting como comparación secundaria:** preentrenado con 20,000 a 100,000 filas simuladas y ajustado con los datos reales.

Bloque 0: Base en Python para datos

Qué estudiar: pandas (leer CSV, filtrar, agrupar), numpy y gráficos básicos con matplotlib.

Recursos:

- **Kaggle Learn** (kaggle.com/learn): los cursos "Python", "Pandas" y "Data Visualization". Son cortos, con ejercicios en el navegador.

Bloque 1: Regresión lineal y su mejora (opción 1)

Qué estudiar:

- Qué es una regresión lineal múltiple y cómo se interpretan los coeficientes.
- Variables categóricas (*dummies*) e interacciones (tipo de negocio × día).
- Sobreajuste y regularización (Ridge y Lasso).

- GLM: por qué una regresión Gamma o Poisson evita predicciones negativas.

Recursos:

- **StatQuest (YouTube, canal de Josh Starmer):** busca "Linear Regression", "Ridge Regression", "Lasso Regression" y "Generalized Linear Models". Son de los más fáciles de entender, con dibujos y paso a paso.
- **An Introduction to Statistical Learning (ISLR):** libro gratis en statlearning.com. Lee el capítulo 3 (regresión lineal) y el 6 (regularización). Tiene versión para Python.
- **Documentación de scikit-learn**, sección "Linear Models", y de **statsmodels** para GLM (statsmodels.org).

Bloque 2: Evaluación y modelos de referencia (opciones 1 y 2)

Este es el bloque más importante para el requisito R-04.

Qué estudiar:

- MAE (error absoluto medio) y por qué comparar siempre contra un modelo base (*baseline*).
- División cronológica de datos (no aleatoria) y por qué evita "ver el futuro".
- Validación cruzada para series de tiempo (`TimeSeriesSplit`).

Recursos:

- **StatQuest:** "Cross Validation" y "Bias and Variance".
- **Forecasting: Principles and Practice** (otexts.com/fpp3, gratis): capítulo 5, secciones sobre métodos simples de referencia (*naive*, *seasonal naive*) y evaluación del pronóstico. Tu "promedio del mismo día de la semana" es básicamente un *seasonal naive*.

Bloque 3: Simulación de datos (opción 3)

Qué estudiar:

- Generar datos aleatorios con numpy (distribuciones normal, Poisson, Gamma).
- Simulación Monte Carlo y semillas aleatorias (reproducibilidad).
- Qué es la brecha simulación-realidad y la aleatorización de dominio.

Recursos:

- Documentación de **numpy random** (`Generator`) con ejemplos.
- En YouTube, busca "Monte Carlo simulation explained" y "synthetic data for machine learning".
- **Documenta tus supuestos:** un anexo con tus parámetros y sus fuentes ya cuenta como buen método.

Bloque 4: Random Forest y Gradient Boosting (opción 4)

Qué estudiar:

- Árboles de decisión, y cómo un bosque promedia muchos árboles.
- Gradient Boosting en lo básico.
- Importancia de variables (para explicar qué pesa más).
- Fine-tuning: cómo reentrenar con datos reales después de datos simulados.

Recursos:

- **StatQuest:** "Decision Trees", "Random Forests" y la serie "Gradient Boost".
- **Kaggle Learn:** cursos "Intro to Machine Learning" e "Intermediate Machine Learning".
- Documentación de scikit-learn: `RandomForestRegressor` y `HistGradientBoostingRegressor`.

Orden recomendado según el cronograma

Cuándo	Qué estudiar
Ahora (semanas 1-2)	Bloque 0 y Bloque 2. Con eso ya puedes definir bien D-2.4 (protocolo, error, referencia).
Semanas 2-4	Bloque 1 y Bloque 3, mientras construyes el simulador.
Semanas 5-7	Bloque 4, cuando ya tengas el pipeline funcionando (I-3.3).

Si tienes poco tiempo

Prioriza solo estos 5 videos de StatQuest: *Linear Regression*, *Cross Validation*, *Ridge Regression*, *Random Forests* y *Generalized Linear Models*. Con ellos y el curso de Pandas de Kaggle puedes empezar a trabajar.

Regla de oro

La evaluación final de R-04 se hace **solo con datos reales de prueba**, comparando contra el modelo de referencia. Si el modelo pierde, el retorno RT01 ya cubre qué hacer.